


ニューラルネットワーク
生物の神経細胞



● しきい値作用

あるしきい値を超えると興奮(非線型)するかどうか。

● 興奮性シナプス

入力側の神経を興奮しやすくする。


● 抑制性シナプス

しにくくする。

入力側神経細胞

各出力側神経細胞からの入力からの総和。

1943年 McCulloch



$$x_k \in \{0, 1\}$$

$$y = f\left(\sum_{k=1}^n w_k x_k - \theta\right)$$

$$f(u) = \begin{cases} 1 & (u \geq 0) \\ 0 & (u < 0) \end{cases}$$


しきい値

Sigmoid 関数.

$$f(u) = \frac{1}{1 + e^{-u}} = (1 + e^{-u})^{-1}$$

$$f'(u) = -(1 + e^{-u})^{-2} = \left(-\frac{e^{-u}}{1 + e^{-u}}\right)$$

$$= \frac{+e^{-u}}{(1 + e^{-u})^2}$$




限りなく 0, 1 に近づく良い関数.

ReLU 関数 (Rectified Linear func. 1993-)

$$R(u) = \max\{0, u\}$$


Remark: ニューラルネットワークの学習には微分できてほしい.



$u=0$ で微分不可

$$f'(u) = \begin{cases} 1 & (u \geq 0) \\ 0 & (u < 0) \end{cases}$$

相互型結合型




Def. (階層型ニューラルネットワーク).

$f: \mathbb{R} \rightarrow \mathbb{R}$, $W \in (w_{ij})$: (i, j) 成分が w_{ij} の実数行列.

$f(W) = (f(w_{ij}))$: (i, j) 成分が $f(w_{ij})$ の実数行列.

- ① 入力層 : 入力層
- ② 中間層 (隠れ層) : 入力層 ~ 出力層
- ③ 出力層 : 出力層



入力層のニューロンの個数: $H^{(0)}$

$$W^{(s)} = H^{(s-1)} \times H^{(s)} \text{ 行列.}$$

$h^{(s)}$: $H^{(s)}$ 次元ベクトル

f : 活性化関数 (Sigmoid 関数等).

$$F_{W^{(s)} h^{(s)}}^{(s)} = f(\alpha W^{(s)} + h^{(s)}) = F^{(s)}(\alpha)$$

$$y = F^{(L)} \circ \dots \circ F^{(2)} \circ F^{(1)}(\alpha)$$

Def (Soft-max 関数)

$$y = (y_1, \dots, y_{H^{(L)}}) \in \mathbb{R}^{H^{(L)}}.$$

$$\text{Soft-max}(y) = \left(\frac{e^{y_1}}{\sum_{i=1}^{H^{(L)}} e^{y_i}}, \dots, \frac{e^{y_{H^{(L)}}}}{\sum_{i=1}^{H^{(L)}} e^{y_i}} \right)$$

確率に変換


$$\mathbf{z} = (z_1, \dots, z_H) \quad \leftarrow \text{偏角がはい}$$

$$\operatorname{argmax}(\mathbf{z}) = \{i \mid z_i = \max_i z_i\}$$


$$\mathbf{z} = \operatorname{Softmax}(\mathbf{y})$$

$$z_1 + z_2 + \dots + z_{H^{(1)}} = 1 \quad \text{分類問題に使える}$$

Example: 画像認識



Example: $\mathbf{z} = (1, 2, 3, 4)$ のとき $\operatorname{argmax} \mathbf{z}$
 $z_1 = 1, z_2 = 2, z_3 = 3, z_4 = 4$ だから
 $\operatorname{argmax} \mathbf{z} = \{4\}$



入力層: クリット分割数, w_{ij} : 任意の重み.

出力層:

$$\mathbf{x} = (x_1, \dots, x_{H^{(1)}})$$

$$(x_1 \dots x_{H^{(1)}}) \begin{pmatrix} w_{11} & \dots & w_{1H^{(1)}} \\ \vdots & & \vdots \\ w_{H^{(1)}1} & \dots & w_{H^{(1)}H^{(1)}} \end{pmatrix}$$

$$i \text{ 成分: } \sum_k x_k w_{kj}$$

Def. (2乗誤差関数: 交差エントロピー)

$$\mathbf{z} = (z_1, \dots, z_m), \mathbf{t} = (t_1, \dots, t_m)$$

$$\text{MSE}(\mathbf{t}, \mathbf{z}) = \frac{1}{2} \sum_{i=1}^m (t_i - z_i)^2 \quad \text{: 2乗誤差関数}$$


$$\text{CE}(\mathbf{t}, \mathbf{z}) = - \sum_{i=1}^m t_i \log z_i \quad \text{: 交差エントロピー}$$

$$(\sum z_i = 1, z_i > 0, \sum t_i = 1, t_i > 0)$$

誤差逆伝播法.

$E(w)$: w の評価関数.

$$w_{\text{new}} = w_{\text{old}} - \eta \frac{\partial E}{\partial w} \quad (\eta: \text{+ 小さい数})$$



Thm

$$1.) \frac{\partial}{\partial z} \text{MSE}(\mathbf{t}, \mathbf{z}) = \mathbf{z} - \mathbf{t}$$

$$2.) \mathbf{z} = \operatorname{Softmax}(\mathbf{z})$$

$$\frac{\partial}{\partial y} \text{CE}(\mathbf{t}, \mathbf{z}) = \mathbf{z} - \mathbf{t}$$

$$\frac{\partial E}{\partial y_i} = \sum_l \frac{\partial E}{\partial z_l} \cdot \frac{\partial z_l}{\partial y_i} = \sum_l \left(- \frac{t_l}{z_l} \right)$$

$$\frac{\partial z_l}{\partial y_i} = \begin{cases} \frac{e^{y_l} (\sum_k e^{y_k}) - (e^{y_l})^2}{(\sum_k e^{y_k})^2} & (i=l) \\ - \frac{e^{y_l} \cdot e^{y_i}}{(\sum_k e^{y_k})^2} & (i \neq l) \end{cases}$$

Thm. Y, X, W, H , 行列とする.

$$Y = XW + H$$

$E(Y)$: 変数 Y の関数

このとき

$$\frac{\partial E}{\partial W} = X^T \frac{\partial E}{\partial Y}, \quad \frac{\partial E}{\partial X} = \frac{\partial E}{\partial Y} W^T.$$

$$\frac{\partial E}{\partial H} = \frac{\partial E}{\partial Y}.$$

pf. $Y = XW + H$ を成分でかくと

$$Y = (y_{ij}), \quad X = (x_{ik}), \quad W = (w_{kj}), \quad H = (h_{ij})$$

$$y_{ij} = \sum_k x_{ik} w_{kj} + h_{ij}$$

$$\frac{\partial E}{\partial W} = \left(\frac{\partial E}{\partial w_{ij}} \right)$$

$$= \sum_{k_1, k_2} \frac{\partial E}{\partial y_{k_1, k_2}} \cdot \frac{\partial y_{k_1, k_2}}{\partial w_{ij}} \quad \text{zzz}$$

$$\frac{\partial y_{k_1, k_2}}{\partial w_{ij}} = \begin{cases} x_{k_1, i} & : k_2 = j \\ 0 & : k_2 \neq j \end{cases} \quad \text{ほか}$$

$$= \sum_{k_1, k_2} \frac{\partial E}{\partial y_{k_1, k_2}} \cdot \frac{\partial y_{k_1, k_2}}{\partial w_{ij}} = \sum_{k_1, k_2} \frac{\partial E}{\partial y_{k_1, k_2}} \cdot x_{k_1, i}$$

$$= \sum_{k_1} x_{k_1, i} \cdot \frac{\partial E}{\partial y_{k_1, j}}$$

$X^{-1} = (x_{ik})$ とあるから

$$\frac{\partial E}{\partial W} = X^T \frac{\partial E}{\partial Y}, \quad \frac{\partial E}{\partial X} = \frac{\partial E}{\partial Y} W^T$$

$$\frac{\partial E}{\partial H} = \sum_{k_1, k_2} \frac{\partial E}{\partial y_{k_1, k_2}} \cdot \frac{\partial y_{k_1, k_2}}{\partial h_{ij}} = \frac{\partial E}{\partial y_{ij}}$$

$$\therefore \frac{\partial y_{k_1, k_2}}{\partial h_{ij}} = \begin{cases} 1 & : (k_1 = i, k_2 = j) \\ 0 & : (\text{その他}) \end{cases}$$

f : 活性化関数とし

$$F^{(s)}(x) = f(xW^{(s)} + h^{(s)}) \quad \text{とおく.}$$

ニューラルネットワークは入力 $x \in \mathbb{R}^{H^{(0)}}$ に対して

$$y = F^{(L)} \circ \dots \circ F^{(2)} \circ F^{(1)}(x)$$

ReLU関数 $f(u) = 1/(1 + \exp(-u))$ は

$$f'(u) = 1/(1 + \exp(-u)) \cdot \exp(-u)/(1 + \exp(-u)) \\ = f(1-f)$$

と表わせる.

また $\tanh(x)$ を用いて

$$f(u) = \tanh(x) = \frac{e^u - e^{-u}}{e^u + e^{-u}} = \frac{1 - e^{-2u}}{1 + e^{-2u}} = \frac{2}{1 + e^{-2u}} - 1$$

$$f'(u) = \frac{4e^{-2u}}{(1 + e^{-2u})^2} = \frac{2}{1 + e^{-2u}} \times \frac{2e^{-2u}}{1 + e^{-2u}} \\ = (f+1)(1-f)$$

と表わせる.

$$z = \text{Softmax}(y)$$

$$x^{(s)} = F^{(s)}(x^{(s-1)}).$$

$$= f(x^{(s-1)} W^{(s)} + h^{(s)}).$$

$$J_{L+1} = \frac{\partial}{\partial y} \text{CE}(t, z) = (z_1 - t_1, z_2 - t_2, \dots, z_{H^{(L)}} - t_{H^{(L)}})$$

$1 \leq s \leq L$ に対して

$$J_s = \frac{\partial}{\partial x^{(s-1)}} \text{CE}(t, z) = \left(\frac{\partial}{\partial x_1} \text{CE}(t, z), \dots, \frac{\partial}{\partial x_{H^{(s)}}} \text{CE}(t, z) \right).$$

とおく.

$\text{diag}(s_1, \dots, s_n)$

$$= \begin{pmatrix} s_1 & & 0 \\ & s_2 & \\ 0 & & \ddots \\ & & & s_n \end{pmatrix}$$

対角成分が
 $s_1, \dots, s_n$
以外は0.

$$\tilde{x}^{(s)} = x^{(s-1)} W^{(s)} + h^{(s)} \text{ に対して}$$

$$\frac{\partial}{\partial \tilde{x}^{(s)}} CE(t, z) = f'(\tilde{x}^{(s)}) \text{diag}(\delta_{s+1})$$

$$x^{(s)} = f(\tilde{x}^{(s)}), \quad x_j^{(s)} = f(\tilde{x}_j^{(s)}).$$

$$\frac{\partial}{\partial \tilde{x}_j^{(s)}} CE(t, z) = \frac{\partial}{\partial x_j^{(s)}} CE(t, z) \cdot \frac{\partial x_j^{(s)}}{\partial \tilde{x}_j^{(s)}}$$

$$= \frac{\partial CE(t, z)}{\partial x_j^{(s)}} \cdot f'(\tilde{x}_j^{(s)}).$$

$$\frac{\partial}{\partial \tilde{x}^{(s)}} CE(t, z) = (f'(\tilde{x}_1^{(s)}), \dots, f'(\tilde{x}_n^{(s)})) \begin{pmatrix} \frac{\partial CE}{\partial x_1^{(s)}} & & 0 \\ & \ddots & \\ 0 & & \frac{\partial CE}{\partial x_n^{(s)}} \end{pmatrix}$$

$$= f'(\tilde{x}^{(s)}) \text{diag}(\delta_{s+1}).$$

$$\delta_s = \frac{\partial}{\partial \tilde{x}^{(s)}} CE(t, z) (W^{(s)})^T$$

$$= f'(\tilde{x}^{(s-1)}) W^{(s)} + h^{(s)} (\text{diag} \delta_{s+1}) (W^{(s)})^T$$

$$\frac{\partial}{\partial W^{(s)}} CE(t, z) = (x^{(s-1)})^T \frac{\partial}{\partial \tilde{x}^{(s)}} CE(t, z).$$

$$= (x^{(s-1)})^T f'(\tilde{x}^{(s-1)}) W^{(s)} + h^{(s)} \text{diag}(\delta_{s+1}).$$

および

$$\frac{\partial}{\partial h^{(s)}} CE(t, z) = \frac{\partial}{\partial \tilde{x}^{(s)}} CE(t, z) = f'(\tilde{x}^{(s-1)}) W^{(s)} + h^{(s)} \text{diag} \delta_{s+1}$$

δ_s は δ_{s+1} から計算できる.

$$W_{\text{new}}^{(s)} = W_{\text{old}}^{(s)} - \eta \frac{\partial}{\partial W^{(s)}} CE(t, z).$$

$$h_{\text{new}}^{(s)} = h_{\text{old}}^{(s)} - \eta \frac{\partial}{\partial h^{(s)}} CE(t, z)$$

ニューラルネットワークの線型分離性

$$f(y) = \begin{cases} 1 & ; y > 0 \\ 0 & ; y \leq 0 \end{cases}$$

$$y = f(x^{(0)} W^{(1)} + h^{(1)})$$

$$x^{(0)} = (x_1, x_2, \dots, x_n)$$

$$W^{(1)} = \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix}, \quad h^{(1)} = h$$

$$y = f\left(\sum_k x_k w_k + h\right)$$

$$y = 1 \text{ となるのは } \sum x_k w_k + h > 0$$

$$y = 0 \quad : \quad \sum x_k w_k + h \leq 0.$$

データの組 $\{(x_1, t_1), \dots, (x_n, t_n)\}$ を用意する. ($t_k = 0$ or 1).


このとき $t_k = 1$ の組と $t_k = 0$ の組に分けるように

$$\sum x_k w_k + h = 0$$

の係数 w_k, h を決定することが **学習 (理論)**



直線を決定することと学習は同じ



← 線型分離性不可.

三層にすれば解決.

$$W^{(1)} = \begin{pmatrix} -2 & 2 \\ -2 & 2 \end{pmatrix}, W^{(2)} = \begin{pmatrix} -2 \\ -2 \end{pmatrix}.$$

$$h^{(1)} = (3, -1), h^{(2)} = 3.$$

$$y = f(f(x W^{(1)} + h^{(1)}) W^{(2)} + h^{(2)})$$

$$\begin{aligned} x W^{(1)} + h^{(1)} &= (x_1, x_2) \begin{pmatrix} -2 & 2 \\ -2 & 2 \end{pmatrix} + (3, -1) \\ &= \begin{pmatrix} -2x_1 - 2x_2 + 3 \\ 2x_1 + 2x_2 - 1 \end{pmatrix}. \end{aligned}$$

$$(2, 2) W^{(2)} + h^{(2)} = -2 \cdot 2 - 2 + 3.$$

N と $n \in \mathbb{N}$, $x_i \in \mathbb{R}^N$

$$x^n = (x_1, \dots, x_n)$$

x_i は Prob. dense func. $g(x_i)$ に ind. に従う.

x^n は $\prod_{i=1}^n g(x_i)$ に従う.

ニューラルネットワークでは

$$x_i = (x_i, t_i)$$

↑画像 ↑教師信号

学習理論の目的: x_i から $g(x_i)$ を推測.

$$\mathbb{E}_x [g(x)] = \int g(x) \cdot g(x) dx.$$

$$\mathbb{E} [g(x^n)] = \int \dots \int g(x_1, \dots, x_n) \prod_{i=1}^n g(x_i) dx_1 \dots dx_n$$

$P(x|w)$ 学習モデル

$\varphi(w)$ 事前 Prob. dense func.

w の事後 Prob. dense func.

$$P(x|w) = \frac{1}{Z_n(\beta)} \varphi(w) \prod_{i=1}^n (x_i | w)^\beta$$

$$Z_n(\beta) = \int \varphi(w) \prod_{i=1}^n P(x_i | w)^\beta dw \quad \text{分配 func.}$$

予測 Prob. dense func.

$$p^*(x) = \int P(x|w) P(x^n | w) dw$$

<Report>

$$P(x|\mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2}\right) \text{ のとき}$$

$$\int_{-\infty}^{\infty} P(x|\mu) dx = 1 \text{ を示せ.}$$

