

三層にすれば解決.

$$W^{(1)} = \begin{pmatrix} -2 & 2 \\ -2 & 2 \end{pmatrix}, W^{(2)} = \begin{pmatrix} -2 \\ -2 \end{pmatrix}.$$

$$h^{(1)} = (3, -1), h^{(2)} = 3.$$

$$y = f(f(x W^{(1)} + h^{(1)}) W^{(2)} + h^{(2)})$$

$$\begin{aligned} x W^{(1)} + h^{(1)} &= (x_1, x_2) \begin{pmatrix} -2 & 2 \\ -2 & 2 \end{pmatrix} + (3, -1) \\ &= \begin{pmatrix} -2x_1 - 2x_2 + 3 \\ 2x_1 + 2x_2 - 1 \end{pmatrix}. \end{aligned}$$

$$(2, 2) W^{(2)} + h^{(2)} = -2 \cdot 2 - 2 + 3.$$

N と $n \in \mathbb{N}$, $x_i \in \mathbb{R}^N$

$$x^n = (x_1, \dots, x_n)$$

x_i は Prob. dense func. $g(x)$ に ind. に従う.

x^n は $\prod_{i=1}^n g(x_i)$ に従う.

ニューラルネットワークでは

$$x_i = (x_i, t_i)$$

↑ 画像 ↑ 教師信号

学習理論の目的: x_i から $g(x_i)$ を推測.

$$\mathbb{E}_x [g(x)] = \int g(x) \cdot g(x) dx.$$

$$\mathbb{E} [g(x^n)] = \int \dots \int g(x_1, \dots, x_n) \prod_{i=1}^n g(x_i) dx_1 \dots dx_n$$

$P(x|w)$ 学習モデル

$\varphi(w)$ 事前 Prob. dense func.

w の事後 Prob. dense func.

$$P(x|w) = \frac{1}{Z_n(\beta)} \varphi(w) \prod_{i=1}^n (x_i | w)^\beta$$

$$Z_n(\beta) = \int \varphi(w) \prod_{i=1}^n P(x_i | w)^\beta dw \quad \text{分配 func.}$$


予測 Prob. dense func.

$$P^*(x) = \int P(x|w) P(w|x^n) dw$$

< Report >

$$P(x|\mu) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2}\right) \text{ のとき}$$

$$\int_{-\infty}^{\infty} P(x|\mu) dx = 1 \text{ を示せ.}$$



r が正しい Prob. dense func.

$$\begin{aligned} r(w|x^n) &= \frac{r(x^n, w)}{r(x^n)} = \frac{r(x^n|w) r(w)}{\int r(x^n, w) dw} \\ &= \frac{r(x^n, w) r(w)}{\int r(x^n, w) r(w) dw} \end{aligned}$$

つまり $r(x^n|w) = P(x^n|w)$

$r(w) = \varphi(w)$ を代入すると

$$P(w|x^n) = \frac{P(x^n|w) \varphi(w)}{\int P(x^n|w) \varphi(w) dw}$$

$$r(\alpha | X^n)$$

$$= \int r(\alpha, w | X^n) dw$$

$$= \int r(\alpha | w, X^n) r(w | X^n) dw$$

$X^n \succeq \alpha$ は ind. より

$$r(\alpha) = r(\alpha | X^n) = \int r(\alpha | w) r(w | X^n) dw$$

$$P^*(\alpha) = \int P(\alpha | w) P(w | X^n) dw$$

$P^*(\alpha)$ は $g(\alpha)$ に近いだろう.

パラメータは $W = \{W^{(1)}, \dots, W^{(L)}, h^{(1)}, \dots, h^{(L)}\}$

$$\text{次元は } d = \sum_{s=1}^L (\underbrace{H^{(s-1)}}_{W \text{ の数}} \times \underbrace{H^{(s)}}_{h \text{ の数}} + H^{(s)})$$

α の Prob. dense func. $g(\alpha)$ は既知とする

これは入力パターンの Prob. dense func.

$$P(t | \alpha, w) = \frac{1}{(2\pi)^{H^{(L)}/2}} \exp\left(-\frac{1}{2} \left\| \underset{\substack{\uparrow \\ H^{(L)} - \dim \text{vec.}}}{t} - F^{(L)} \circ \dots \circ F^{(2)} \circ F^{(1)}(\alpha) \right\|^2\right)$$

$$P(t | \alpha, w) = P(t | \alpha, w) g(\alpha) \text{ とする.}$$

これは正規分布 $\mathcal{N}(t | E, \sigma)$ から発生する正規ノイズから出力 t に加えられている.

$$t = F^{(L)} \circ \dots \circ F^{(2)} \circ F^{(1)}(\alpha) + \text{正規ノイズ}$$

A は正定値行列 $\Leftrightarrow$ 固有値が正

$$\mathcal{N}(\alpha | A, \mu)$$

$$= \frac{1}{(2\pi)^{H/2} \sqrt{\det A}} \exp\left(-\frac{\tau(\alpha - \mu) A^{-1} (\alpha - \mu)}{2}\right)$$

$$\tau P A P = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_H \end{pmatrix} \quad P: \text{直交行列.}$$

<Report> $\mathcal{N}(\alpha | A, \mu)$ を積分すると 1 になることを示せ.
 $\int_{\mathbb{R}^H} d\alpha$

$$\odot y = \tau P(\alpha - \mu) \rightarrow Py = \alpha - \mu$$

$$\tau(\alpha - \mu) A^{-1} (\alpha - \mu)$$

$$= \tau y^T P A^{-1} P y$$

$$= \tau y^T \begin{pmatrix} 1/\lambda_1 & & \\ & \ddots & \\ & & 1/\lambda_H \end{pmatrix} y$$

$$= \frac{1}{\lambda_1} y_1^2 + \dots + \frac{1}{\lambda_H} y_H^2$$

$$\odot \sqrt{\det A} = \sqrt{\lambda_1 \times \dots \times \lambda_H}$$

Def (Kullback-Leibler 距離).
 相対エントロピー

$p \geq q$ は Prob. dense func

$$K(q(x) \| p(x)) = \int q(x) \cdot \log \frac{q(x)}{p(x)} dx$$

Remark: $K(q \| p)$ は ~~dis~~ metric def のうち

$$d(x, y) \geq 0, d(x, y) = 0 \Leftrightarrow x = y \text{ のみをみたす.}$$

Remark が成り立つことを示す.


pf. $S(t) = e^{-t} + t - 1$

$$S'(t) = -e^{-t} + 1 = 0$$

$$t \quad \parallel \quad \dots \quad 0 \quad \dots$$

$$S'(t) \quad \parallel \quad - \quad 0 \quad +$$

$$S(t) \quad \parallel \quad \searrow \quad 0 \quad \nearrow$$



$$S(t) \geq 0 \quad S(t) = 0 \Leftrightarrow t = 0$$